

Informe Final: Proyecto de Minería de Datos - Análisis de Usuarios de Streaming

1. Marco Introductorio y Alcance del Proyecto

En el actual paradigma de la economía de la atención, la minería de datos se erige como la disciplina crítica para transmutar flujos masivos de información en activos informacionales con valor estratégico. Para las plataformas de streaming, el análisis del comportamiento del usuario no es simplemente un ejercicio descriptivo, sino un requisito indispensable para la mitigación de riesgos de fuga (*churn*) y la optimización de la personalización de contenidos en un mercado de competencia perfecta. Este proyecto despliega un ecosistema analítico diseñado para desentrañar la complejidad del consumo digital a través de un rigor metodológico exhaustivo. El propósito central de este estudio se articula bajo los siguientes objetivos estratégicos:

- **Identificación de patrones de consumo:** Decodificar tendencias subyacentes y comportamientos recurrentes para anticipar la demanda.
 - **Auditoría de integridad de activos:** Evaluar y garantizar la calidad de los datos, asegurando una base libre de sesgos técnicos.
 - **Reducción de dimensionalidad multivariante:** Aplicar técnicas de síntesis matemática para simplificar estructuras complejas sin sacrificar la varianza explicativa.
 - **Comunicación de hallazgos estratégicos:** Traducir métricas técnicas en narrativas de negocio que faciliten la toma de decisiones ejecutivas.
- Información Institucional**
- **Consultor Analista:** Fabricio Fabián Loza
 - **Docente Supervisor:** Fernando Mubarqui
 - **Comisión:** X
 - **Fecha de Entrega:** Julio 2026
- La arquitectura de cualquier modelo de aprendizaje automático es tan robusta como los datos que la sustentan; por lo tanto, el éxito de este análisis depende de una gestión estricta del linaje de datos y de la mitigación de riesgos tipo *garbage-in/garbage-out*.

2. Auditoría de Calidad y Procesamiento de Datos (Pipeline)

La fase de preparación no se considera una etapa previa, sino el cimiento de la integridad analítica. Un procesamiento riguroso es el único mecanismo capaz de neutralizar el ruido estadístico y las inconsistencias que podrían invalidar las inferencias posteriores. El flujo de trabajo documentado en este proyecto asegura una trazabilidad total desde el origen de los datos en *data/raw/* hasta su estado refinado para modelización. A continuación, se presenta la métrica de progresión del pipeline de datos:

Paso	Descripción	Filas	Nulos	Retención (%)
1	Dataset original (Raw)	1000	120	100%
2	Mitigación de nulos y limpieza	880	0	88%
3	Normalización y Codificación	880	0	88%

Para garantizar la viabilidad de los algoritmos de reducción de dimensionalidad, se ejecutó una limpieza exhaustiva que incluyó la eliminación de duplicados y la normalización de variables numéricas. Esta última es crítica: dado que los algoritmos basados en varianza son sensibles a la escala, se estandarizaron métricas como "edad" y "horas de streaming"

para evitar que variables con rangos numéricos más amplios dominaran injustificadamente el modelo. La reproducibilidad técnica del proceso está blindada mediante el dataset procesado en `data/processed/streaming_users_clean (2).json` y el historial de operaciones en `logs/pipeline_log.csv`. Esta fase de saneamiento permite la transición desde una colección de registros crudos hacia una estructura de datos de alta fidelidad, apta para la extracción de conocimiento significativo.

3. Análisis Exploratorio de Datos (EDA) y Comportamiento del Consumidor

El Análisis Exploratorio de Datos (EDA) actúa como el radar estratégico del proyecto, permitiendo la identificación de señales de valor antes de la implementación de modelos avanzados. No buscamos solo describir, sino comprender la causalidad potencial que rige el compromiso del usuario. Los hallazgos extraídos de este proceso mandatan acciones estratégicas específicas:

- **Intensidad de uso correlacionada con la edad:** Se observa que los segmentos de usuarios más jóvenes (Gen Z y Millennials) concentran la mayor densidad de horas de consumo. Esto sugiere que las estrategias de retención deben priorizar la actualización constante de catálogos y modelos de interacción de alta frecuencia para estos grupos.
- **Impacto de la arquitectura de suscripción:** El nivel de consumo está condicionado por el tipo de plan, lo que revela oportunidades críticas para el *upselling* y la optimización de los *tiers* de servicio según el valor de vida del cliente (CLV).
- **Diferenciación de consumo por género:** Las variaciones estadísticas detectadas por género permiten una curaduría de contenido personalizada, optimizando la relevancia de las recomendaciones y, por ende, el *engagement* orgánico. La profundidad técnica de estos hallazgos se encuentra disponible en los notebooks de trabajo (`03_eda.ipynb`) y en la aplicación interactiva de Streamlit. Sin embargo, para capturar la interrelación multivariante de estos factores, es imperativo trascender la visualización univariada mediante la síntesis matemática.

4. Análisis de Componentes Principales (PCA) y Reducción de Dimensionalidad

El PCA se implementó como una técnica de ingeniería de características para visualizar la estructura de datos en un plano bidimensional, permitiendo identificar agrupamientos de usuarios que no son evidentes en el espacio original de altas dimensiones. El procedimiento técnico fue riguroso: se aplicó un escalamiento *Z-score* previo para asegurar que cada variable contribuyera equitativamente a la maximización de la varianza. Los dos primeros componentes principales obtenidos explican la mayor parte de la varianza acumulada. En términos estratégicos, esto indica que el primer componente actúa probablemente como un índice de "Intensidad de Engagement", sintetizando el volumen de uso y la madurez del perfil del usuario. Este enfoque reduce la "maldición de la dimensionalidad" y permite una inspección visual clara de las fronteras de comportamiento, disponible para análisis detallado en `notebooks/04_pca.ipynb` y mediante la interfaz de Streamlit. Esta simplificación es la que nos permite, finalmente, reconocer el alcance actual del modelo y sus áreas de expansión.

5. Diagnóstico de Limitaciones y Hoja de Ruta (Próximos Pasos)

Desde una perspectiva de consultoría senior, la transparencia sobre las limitaciones es fundamental para la validez científica del proyecto. Todo modelo es una simplificación, y reconocer sus fronteras es el primer paso para su evolución. Se han diagnosticado las siguientes restricciones:

- **Volumen de datos:** El tamaño actual del dataset limita la capacidad de generalización para fenómenos de nicho.
- **Sesgo de muestreo:** La representatividad de la muestra actual podría estar condicionada por factores demográficos no controlados en la recolección inicial.

Estrategia de Evolución (Roadmap):

1. **Enriquecimiento de datos:** Integración de fuentes externas, incluyendo metadatos demográficos avanzados y análisis de sentimiento proveniente de redes sociales para robustecer el perfil del usuario.
2. **Transición a Modelización Predictiva:** Evolucionar del análisis descriptivo actual hacia modelos de *Churn Prediction* (predicción de bajas) y *Propensity Modeling* para identificar usuarios con alta probabilidad de migrar a planes premium. El proyecto ha cumplido con éxito los objetivos de cimentación analítica, estableciendo una plataforma escalable y técnicamente sólida para futuros despliegues de inteligencia artificial aplicada.

6. Directorio de Recursos y Repositorios

Para la auditoría técnica del código, el linaje de datos y la visualización de los resultados en tiempo real, se ponen a disposición los siguientes recursos:

- **Repositorio GitHub:** https://github.com/Farchofl/PI_Mineria_Datos_1.git
- **Aplicación Streamlit:** Streamlit Cloud